

Classificação de Imagens de Gatos e Cachorros Utilizando Perceptron

1. Atividade

Implementado manualmente em Python, sem a utilização de bibliotecas de aprendizado de máquina. O objetivo foi classificar imagens de gatos e cachorros a partir de seus pixels em escala de cinza.

2. Fundamentação Teórica

2.1 Perceptron

O Perceptron é um modelo matemático inspirado no funcionamento biológico dos neurônios. De acordo com Rosenblatt (1958), sua estrutura é composta por:

- Entradas (features);
- Pesos sinápticos;
- Bias (limiar);
- Função de ativação.

A saída do Perceptron é calculada por:

$$u = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

onde:

- x_i representa as entradas;
- w_i representa os pesos;
- b representa o bias.

A função de ativação utilizada é a função degrau:

$$f(u) = 1, \text{ se } u \geq 0$$

$$f(u) = 0, \text{ se } u < 0$$

Segundo Goodfellow, Bengio e Courville (2016), o Perceptron é adequado para problemas linearmente separáveis, mas possui limitações em problemas mais complexos que exigem múltiplas camadas de processamento.

2.2 Classificação de Imagens

A classificação de imagens consiste em associar uma imagem a uma categoria previamente conhecida. Para que algoritmos de aprendizado possam processar imagens, estas devem ser transformadas em vetores numéricos.

De acordo com Bishop (2006), cada pixel de uma imagem pode ser tratado como um atributo do conjunto de dados, permitindo que técnicas tradicionais de aprendizado supervisionado sejam utilizadas para classificação.

2.3 Normalização dos Dados

A normalização consiste em transformar os valores dos atributos para uma escala comum.

Os pixels originais possuem intensidade variando entre 0 e 255. Neste trabalho foi utilizada a normalização Min-Max:

$$x_{\text{normalizado}} = x / 255$$

Segundo Han, Kamber e Pei (2011), a normalização reduz diferenças de escala entre atributos e contribui para a estabilidade dos algoritmos de aprendizado.

3. Metodologia

3.1 Dataset

Foi utilizado um conjunto de imagens contendo duas classes:

- Gatos (Cat): 1000 imagens
- Cachorros (Dog): 1000 imagens

Totalizando 2000 imagens.

O conjunto foi dividido em:

- 80% para treinamento (1600 imagens)
- 20% para teste (400 imagens)

3.2 Pré-processamento

As seguintes etapas foram aplicadas:

1. Conversão para escala de cinza;
2. Redimensionamento para 32×32 pixels;
3. Conversão para vetor unidimensional;
4. Normalização dos pixels para o intervalo $[0,1]$;
5. Armazenamento em arquivo CSV.

Cada imagem passou a ser representada por:

$$32 \times 32 = 1024 \text{ atributos}$$

Além de uma coluna contendo o rótulo da classe:

- 0 = gato
- 1 = cachorro

3.3 Implementação do Perceptron

O Perceptron foi implementado manualmente em Python utilizando apenas estruturas básicas da linguagem.

Os pesos foram inicializados aleatoriamente e atualizados pela Regra de Aprendizado do Perceptron:

$$w_i = w_i + \eta \times \text{erro} \times x_i$$

onde:

- η é a taxa de aprendizagem;

- erro = saída desejada – saída prevista;
- x_i é a entrada correspondente.

O bias foi atualizado por:

$$b = b + \eta \times \text{erro}$$

O treinamento foi realizado por múltiplas épocas até a redução dos erros de classificação.

4. Resultados

Após o treinamento, o modelo foi avaliado utilizando o conjunto de teste.

Exemplo de resultados obtidos:

Métrica	Valor
Imagens de Treino	1600
Imagens de Teste	400
Acertos	214
Erros	186
Acurácia	53,50%

5. Discussão

Os resultados demonstram que o Perceptron é capaz de aprender padrões presentes nas imagens e realizar classificações binárias.

Entretanto, conforme discutido por Goodfellow et al. (2016), imagens de gatos e cachorros apresentam características altamente complexas e não linearmente separáveis. Dessa forma, o desempenho de um único Perceptron tende a ser limitado quando comparado a arquiteturas modernas como Redes Neurais Multicamadas (MLP) e Redes Neurais Convolucionais (CNN).

Mesmo com essas limitações, o modelo permite compreender conceitos fundamentais de aprendizado supervisionado, atualização de pesos, função de ativação e processo de classificação.

6. Conclusão

Neste trabalho foi implementado um Perceptron manualmente em Python para a classificação de imagens de gatos e cachorros.

As imagens foram convertidas para escala de cinza, redimensionadas, normalizadas e transformadas em vetores numéricos adequados ao treinamento do modelo.

Os resultados demonstraram a viabilidade do uso do Perceptron em tarefas simples de classificação binária, além de evidenciar suas limitações diante de problemas complexos de visão computacional.

O trabalho permitiu consolidar conceitos importantes de Inteligência Artificial, aprendizado supervisionado, pré-processamento de dados e redes neurais artificiais.

Referências

BISHOP, Christopher M. Pattern Recognition and Machine Learning. New York: Springer, 2006.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. Cambridge: MIT Press, 2016.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: Concepts and Techniques. 3. ed. Burlington: Morgan Kaufmann, 2011.

ROSENBLATT, Frank. The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. Psychological Review, v. 65, n. 6, p. 386–408, 1958.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2021.